

FranceScope — Étude de cas LLM Engineering

Context engineering, contrôle des agents, évaluation et orchestration humain-IA

FranceScope est devenu un laboratoire pratique pour apprendre à transformer des LLM puissants mais imparfaits en un workflow long, contrôlé, traçable et orienté résultat.

CONTEXTE

CONTRÔLE

ÉVALUATION

JUGEMENT
HUMAIN

Python · Pandas · Matplotlib · CSV/JSON/Markdown · VS Code · Git/GitHub · workflows multi-modèles

Le problème n'était pas une réponse isolée

Il fallait maintenir la cohérence sur de nombreuses sessions

Direction · état · scope · qualité · intégrité des sources · discipline d'exécution

Échelle locale

Une réponse peut être brillante, plausible et utile pour la dernière question.

Échelle projet

Conserver décisions, définitions et limites pendant plusieurs semaines.

Un LLM peut être très intelligent localement tout en étant peu fiable à l'échelle d'un projet de plusieurs semaines.

Les modes d'échec qui ont changé le workflow

Échec	Risque concret
Dérive du modèle	La dernière tâche prend le dessus sur l'objectif.
Perte d'état	Une décision gelée redevient une question ouverte.
Approche ratée répétée	Temps et tokens sans information nouvelle.
Boucle d'exploration	Recherche prolongée sans réduction d'incertitude.
Action hors scope	Risque de régression sans pouvoir de décision.
Surédiction	Une modification après validation réintroduit un défaut.
Plausibilité locale	Des sorties séparées deviennent globalement incompatibles.
Confusion de source	Un taux est pris pour un niveau comparable.
Forecast / projection	Des objets méthodologiquement différents sont fusionnés.

Du prompt au context engineering

Le prompt est une partie du système, pas le système entier

Approche initiale	Pratique mature
Écrire une meilleure instruction	Contrôler l'état autoritatif
Ajouter du contexte	Sélectionner le contexte pertinent
Demander une réponse	Définir actions, fichiers et scope
Continuer jusqu'à satisfaction	Fixer des gates et des conditions d'arrêt
Faire confiance à la sortie	Tracer la provenance et tester la cohérence

Systeme contrôlé

Etat gelé · scope · fichiers autorisés · provenance · évaluation · handoffs

Anti-loop, changement de stratégie et exploration bornée

Règle 1

Never repeat the exact same failed tool call.

Règle 2

If an approach fails twice without measurable progress, change hypothesis, tool, command, file, or implementation strategy.

Exploration bornée

Sources définies · lectures capées · stop condition

Pertinence

Chaque appel d'outil doit avancer la tâche

Tokens

Moins de contexte, mieux sélectionné

Scope, état gelé, handoffs et arrêt

Scope

Workspace actif
Fichiers autorisés
Mode : recherche / édition / validation / présentation

Etat gelé

Couche validée
autoritative
Réouverture seulement via revue formelle

Smallest safe change

Corriger le problème démontré
Réduire les régressions
Faciliter l'audit

Handoff structuré

PROJECT_VERSION · VALUES_CHANGED · FILES_UPDATED
VALIDATION · VERDICT · NEXT_ACTION

Stop conditions

Pas d'audit après validation
Pas de refactorisation opportuniste
Pas de réouverture d'un sujet gelé

Les conditions d'arrêt font partie de la spécification.

De la génération à la décision

generate → accept

generate → test → revise / reject / freeze

Intégrité

Données · valeurs · formats · manifests

Cohérence

Scénarios · horizons · temporal · cross-variable

Provenance

Sources · classification · traceabilité · revue adversariale

Le modèle générait des candidats ; le framework décidait s'ils étaient acceptables.

Revue adversariale et raisonnement orienté provenance

candidat



critique externe



hypothèse testable

→ **revision gate**

Pas un vote

Des modèles indépendants critiquent.
Le désaccord est utile lorsqu'il devient un test reproductible.

Taxonomie des sources

OBSERVED · DIRECT_FORECAST
LONG_RUN_PROJECTION
STRUCTURAL_ASSUMPTION · DERIVED_PROXY

Champs contrôlés

Source · date · variable exacte · type · horizon · justification · confiance · transformations

Quand un calcul juste produit une conclusion fausse

Source

Jalons CE de croissance GDPpc

Transformation

Composition mathématique possible

Erreur

Taux constant + niveau
comparable jusqu'en 2050

→ **trajectoire EUR/person dérivée retirée**

Leçon

Valider provenance et sémantique
avant transformation.

Politique NA

GDPpc comparable : non
Médian comparable : non
NA conservé.

Une opération mathématique peut être correcte et son utilisation méthodologiquement fausse.

Human-in-the-loop : accélérer sans déléguer l'architecture

Les LLM ont accéléré

- Recherche
- Code
- Extraction
- Synthèse
- Critique
- Documentation

J'ai conservé la responsabilité de

- Objectif et architecture
- Sens des scénarios
- Confiance dans les sources
- Critères d'acceptation
- Ce qu'il fallait geler ou simplifier

Human-directed, machine-accelerated — not model-autonomous.

Les modèles n'ont pas décidé seuls de la structure finale, de la confiance accordée aux sources ou de l'acceptation des résultats.

Ce que le projet a changé dans ma pratique

Instinct initial	Pratique mature
Ajouter du détail au modèle	Réduire la surface de prévision
Ajouter du raisonnement	Renforcer les évaluations
Ajouter du contexte	Curater le contexte
Réessayer	Forcer un changement de stratégie
Recherche ouverte	Exploration bornée
Etat conversationnel	Etat gelé et handoffs
Confiance dans un modèle	Revue adversariale
Remplir les trous	Préférer NA
Conserver les abstractions	Retirer l'Index inutile

Leçons clés et compétences démontrées

Capacité $\neq$ fiabilité · Prompt seul insuffisant · Etat explicite · Evaluation avant acceptation · Stop conditions · Contexte sélectionné · Revue multi-modèles testable · Provenance · NA · Jugement humain

Context engineering

Scope · état gelé · handoffs

Agent control

Anti-loop · exploration bornée

Evaluation

Temporal · cross-variable · adversarial

Provenance

Typage · horizon · NA

Data / software

Python · CSV · validation

Human-in-the-loop

Arbitrage · architecture · gel

Ce que cette étude ne prétend pas

Limites

Pas une plateforme d'agents autonomes en production.
Tous les contrôles ne sont pas imposés par un framework dédié.
La revue multi-modèles n'est pas une peer review scientifique.

Reste vrai

Les workflows dépendent des sources, de la discipline d'exécution et du jugement humain.
La prévision de long terme reste incertaine.

L'ingénierie LLM ne consiste pas seulement à obtenir de bonnes réponses.

Elle consiste à construire un environnement dans lequel les erreurs deviennent détectables, les décisions traçables, le contexte contrôlable et l'arrêt explicite.

Le projet est devenu plus fiable à mesure que le workflow devenait plus contraint, plus testable et plus human-directed.